



Hỏi đồ hỏi đáp

Vessel Chat — tài liệu tổng quan giải pháp

Hỏi về tàu biển bằng tiếng Việt, nhận câu trả lời **có chứng cứ** và bản đồ

Chatbot AI tra cứu dữ liệu AIS, đăng kiểm và chủ sở hữu: tàu của ai, đang ở đâu, đã đi những đâu, có tắt tín hiệu bất thường không. Tài liệu trình bày yêu cầu, cách hoạt động, công nghệ, bảo mật, tối ưu, ứng dụng và hướng mở rộng.

1.000

tàu, 171.073 điểm AIS, 10–
12/09/2026

45/45

ca đánh giá tự động đạt, gồm
cả red-team

100%

câu trả lời dùng dữ liệu đều có
mã chứng cứ

~0,0015\$

chi phí LLM trung bình mỗi câu
hỏi

Tóm tắt

Giải pháp trong một trang

Người phân tích hàng hải cần trả lời nhanh những câu hỏi như “tàu này của ai”, “lúc 21:00 nó ở đâu”, “ngày hôm qua nó đi bao xa”, “có lần nào tắt AIS không”. **Hỏi đồ hỏi đáp** cho phép hỏi các câu đó bằng tiếng Việt, hỏi nối tiếp nhiều lượt, và nhận câu trả lời hiện dần theo thời gian thực, kèm bản đồ và **chứng cứ truy được về từng bảng dữ liệu**.

10

công cụ truy vấn có tham số
(không text-to-SQL)

4 lớp

bộ nhớ: trạng thái, tóm tắt,
vector, cửa sổ

189

test tự động backend, + 17
test frontend

5,4 s

thời gian trung vị cho một
lượt hỏi đáp



Đã đáp ứng

- Toàn bộ yêu cầu R1–R4, nâng cao N1→N3 và tài liệu D1–D3 của đề.
- API chat streaming (SSE) với các sự kiện có kiểu; hội thoại lưu bền, chạy song song.
- Bộ nhớ dài hạn vượt context window (pgvector), kiểm chứng với cửa sổ chỉ 2 lượt.
- Giao diện web: danh sách hội thoại, câu trả lời theo thời gian thực, bản đồ vẽ tới hàng chục nghìn điểm.



Nâng lên mức sản phẩm AI

- Chứng cứ** [E#] cho mọi câu trả lời và tự động đối chiếu số liệu.
- Guardrails**: chặn prompt injection, kiểm duyệt, che khoá bí mật, giới hạn phạm vi.
- Đăng nhập**: chỉ tài khoản được cấp mới dùng được chatbot và API.
- Không phụ thuộc một nhà cung cấp AI**: có AI dự phòng, AI kiểm chứng độc lập, và chạy được cả khi không có AI.
- RAG**: kho tri thức hàng hải, tìm kiếm lại, có trích dẫn.
- Harness đánh giá**, bảo mật nhiều lớp, cache, metrics, SEO/GEO.

Mục lục

1 Bài toán và yêu cầu

2 Ứng dụng thực tế

3 Kiến trúc tổng thể

4 Cách một câu hỏi được xử lý

5 Dữ liệu, công cụ và chứng cứ

6 Công nghệ sử dụng

7 Bảo mật

8 Tối ưu và hiệu năng

9 Chất lượng và kiểm thử

10 Hướng mở rộng

11 Giao diện

12 Thống kê vận hành

13 Phụ lục: cài đặt và API

Nguyên tắc xuyên suốt: mô hình ngôn ngữ không bao giờ tự bịa số liệu. Mọi con số và tên đều lấy qua công cụ truy vấn cơ sở dữ liệu; mỗi lần truy vấn có mã chứng cứ; hệ thống tự đối chiếu câu trả lời với dữ liệu đã lấy trước khi kết thúc lượt.

1 Bài toán và yêu cầu

Đề bài: chatbot tra cứu tàu biển, API streaming, bộ nhớ dài hạn, dữ liệu thật

Tàu biển liên tục phát bản tin AIS (vị trí, tốc độ, hướng đi). Kết hợp với dữ liệu đăng kiểm và chủ sở hữu, người phân tích cần tra cứu nhanh bằng ngôn ngữ tự nhiên, hỏi nối tiếp trong một cuộc trò chuyện dài.

Dữ liệu đầu vào

Bảng	Số dòng	Nội dung	Đặc điểm cần xử lý
ais_positions	171.073	Vị trí, tốc độ, hướng, trạng thái hành hải của tàu trong vùng 102–118°E, 6–23°N	Điểm GPS nhảy; khoảng trống khi tàu rời vùng
vessels	1.000	MMSI, IMO, hô hiệu, cờ, loại tàu, kích thước, trọng tải, năm đóng	Tên rỗng hoặc gần trùng; nhãn loại tàu tiếng Anh
dark_gaps	880	Sự kiện mất tín hiệu AIS từ 3 giờ trở lên	Khác đôi chút so với khe tính từ điểm vị trí
ownership	4.127	Quan hệ tàu – công ty theo 6 vai trò	Tên công ty có biến thể; 259 tàu không có dữ liệu

Yêu cầu và mức độ hoàn thành

Mã	Yêu cầu	Cách đáp ứng	Kết quả
R1	Nạp dữ liệu, schema, chỉ mục; truy vấn có tham số; tìm tàu linh hoạt	Nạp lại không nhân đôi (một transaction, ~8 s); GiST/B-tree/trigram; tìm theo tên sai chính tả, MMSI, IMO, hô hiệu; hỏi lại khi trùng	Đạt
R2	API hội thoại; chat streaming; sự kiện token/tool_call/done/error	SSE với 10 loại sự kiện; lỗi không làm treo kết nối; khoá theo hội thoại, các hội thoại chạy song song	Đạt
R3	Lưu bền; hiểu câu nối tiếp; bộ nhớ vector khi vượt context window	Postgres + pgvector; trạng thái đối tượng đang bàn; tóm tắt + truy xuất vector; cửa sổ cấu hình được	Đạt
R4	Thông tin tàu/chủ sở hữu, vị trí theo thời điểm, hành trình, dark gap	Nội suy vị trí; quãng đường, tốc độ, GeoJSON; tốc độ trước/sau khi mất tín hiệu; nói rõ khi thiếu dữ liệu	Đạt
N1	Giao diện chat	React + Vite: danh sách, tạo mới, mở lại, xoá; câu trả lời theo thời gian thực	Đạt
N2	Bản đồ theo câu hỏi, qua sự kiện có cấu trúc	Sự kiện <code>data</code> mang <code>data_id</code> ; “hiện thêm lần tắt AIS của nó” thêm lớp mới	Đạt
N3	Nhiều hành trình trên bản đồ / qua API	API phân trang; chat “tất cả tàu của công ty X”; 484 tàu, 35,7 nghìn điểm vẽ bằng WebGL	Đạt
D1–D3	README, tài liệu nghiên cứu và kiến trúc, test và transcript	README, <code>.env.example</code> đủ mọi biến, research/architecture/api, 189 test, transcript 9 bộ kịch bản	Đạt

Ràng buộc quan trọng của đề và cách tuân thủ: không hardcode (mọi khoá, URL, model, ngưỡng đều qua biến môi trường); không đưa CSV vào prompt (LLM chỉ nhận bản tóm tắt từ công cụ); không viết sẵn câu trả lời hay tên tàu (kiểm chứng bằng câu hỏi sinh ngẫu nhiên từ dữ liệu).

2 Ứng dụng thực tế

Ai dùng, dùng vào việc gì

Dữ liệu AIS kết hợp đăng kiểm và chủ sở hữu là nguồn thông tin cốt lõi của ngành hàng hải. Công cụ hỏi đáp giúp người không chuyên SQL hay GIS khai thác được nguồn này trong vài giây.

Tuân thủ và trừng phạt

Rà soát chủ sở hữu hưởng lợi, cờ, đội tàu cùng chủ; phát hiện tàu tắt AIS gần khu vực nhạy cảm, nghi chuyển tải hàng trên biển.

Giám sát nghề cá

Theo dõi tàu cá, các lần mất tín hiệu dài, vùng hoạt động — hỗ trợ chống khai thác bất hợp pháp (IUU).

Logistics và chuỗi cung ứng

Hỏi vị trí tàu, quãng đường, tốc độ trung bình, cảng đích khai báo để ước tính thời gian đến và theo dõi lô hàng.

Bảo hiểm và thẩm định

Kiểm tra lịch sử hành trình, hành vi bất thường, thông tin quản lý kỹ thuật trước khi nhận bảo hiểm hoặc cho vay.

Cảng vụ và cơ quan quản lý

Tra cứu nhanh tàu sắp đến, trạng thái neo đậu, nhà khai thác; tổng hợp tàu theo loại trong một ngày.

Tìm kiếm cứu nạn

Xác định vị trí cuối cùng có dữ liệu, điểm mất tín hiệu và tàu ở gần — trả lời có dẫn chứng để ra quyết định.

Ví dụ một cuộc trò chuyện

Tàu nào mất tín hiệu AIS lâu nhất? Mất ở đâu và xuất hiện lại ở đâu?

Tàu **WORLD SPIRIT** (MMSI 636011023) mất tín hiệu 2 ngày 15 giờ 48 phút, từ 00:13 ngày 10/09 đến 16:01 ngày 12/09/2026 **E1**. Vị trí mất: 9.06653, 102.82848; vị trí có lại: 8.53101, 103.85132 **E1**.

✓ Đã đối chiếu 9 số liệu với dữ liệu truy vấn

Trước khi mất tín hiệu, tàu chạy với tốc độ bao nhiêu?

Tàu chạy 11.6 hải lý/giờ, theo điểm AIS cuối cùng lúc 00:13:09 **E1**.


Người dùng hỏi được gì

- **Danh sách tàu:** “có bao nhiêu tàu cá, kể tên?”, “5 tàu trọng tải lớn nhất?”
- **Hồ sơ tàu và chủ sở hữu:** “tàu KOTA GAYA của ai?”, “công ty đó còn tàu nào khác?”
- **Vị trí theo thời điểm:** “lúc 21:00 ngày 11/09 (UTC) nó ở đâu?” — có nội suy và độ lệch thời gian.
- **Hành trình:** “MMSI 563240200 đi từ đâu đến đâu ngày 11/09?”, “ngày hôm sau đi xa hơn không?”
- **Mất tín hiệu:** thời gian, độ dài, vị trí mất/có lại, tốc độ trước và sau.
- **Cả đội tàu:** “hiển thị hành trình tất cả tàu do Evergreen khai thác”, “toàn bộ tàu dầu ngày 12/09”.
- **Kiến thức nghiệp vụ:** “At anchor khác Moored thế nào?”, “DWT khác GT ra sao?”
- **Bộ nhớ dài:** “hồ sơ tôi nhắc từ đầu có mã gì?” — sau hàng chục lượt.

Câu hỏi ngoài phạm vi (làm thơ, thời tiết...) được từ chối lịch sự; câu hỏi về tàu mà dữ liệu không có (thuyền trường, hàng hoá) được trả lời rõ là “dữ liệu không có”.

3 Kiến trúc tổng thể

Ba khối: giao diện, dịch vụ API, một cơ sở dữ liệu duy nhất



Mũi tên magenta: gọi dịch vụ AI. Toàn hệ thống chạy bằng một lệnh docker compose (db, api, web).

Năm nguyên tắc thiết kế



LLM không thấy dữ liệu thô

Công cụ chỉ trả bản tóm tắt có giới hạn. Dữ liệu bản đồ (GeoJSON, có thể vài MB) đi thẳng tới trình duyệt qua mã `data_id`, không đi qua mô hình — nhanh hơn, rẻ hơn, không bị bịa.



Không text-to-SQL

Mô hình chỉ chọn công cụ và tham số; câu lệnh SQL được viết sẵn và tham số hoá. Kết quả ổn định, kiểm thử được, không có đường cho SQL injection.



Mọi câu trả lời có chứng cứ

Mỗi kết quả công cụ mang mã **E#** gồm bảng nguồn, tham số và giá trị gốc; hệ thống đối chiếu số liệu trước khi kết thúc lượt.



Phòng thủ nhiều lớp

Guardrail đầu vào → phạm vi trong prompt → công cụ chỉ đọc → lọc đầu ra. Một lớp bị vượt qua thì lớp sau vẫn giới hạn thiệt hại.

Một cơ sở dữ liệu cho tất cả: PostgreSQL chứa dữ liệu không gian (PostGIS), tìm kiếm mờ (pg_trgm), vector (pgvector) và hội thoại. Người chấm chỉ cần một container dữ liệu; sao lưu, xoá hội thoại và giao dịch đều nhất quán. Mọi thiết lập (khóa, URL, model, ngưỡng) nằm trong biến môi trường.

4 Cách một câu hỏi được xử lý

Từ lúc người dùng bấm gửi đến khi câu trả lời hoàn tất (trung vị 5,4 giây)

- Kiểm soát cửa vào.** Xác thực API key, giới hạn tần suất, kích thước; gán mã yêu cầu để truy vết log.
- Guardrail đầu vào.** Chấm điểm dấu hiệu prompt injection (tiếng Việt, tiếng Anh) và kiểm duyệt nội dung. Nếu vi phạm: trả lời từ chối ngay, không tốn lượt gọi LLM.
- Dựng ngữ cảnh từ bộ nhớ.** Đối tượng đang bàn, bản tóm tắt, ký ức tìm theo ngữ nghĩa và vài lượt gần nhất nguyên văn.
- LLM chọn công cụ.** gpt-4o-mini đọc câu hỏi và mô tả 10 công cụ, gọi một hoặc nhiều công cụ song song với tham số (tàu, thời gian, công ty...).
- Công cụ truy vấn dữ liệu.** SQL có tham số trên pool chỉ đọc (hoặc kho tri thức). Có cache nên câu hỏi lặp lại trả trong vài phần mười mili giây.
- Phát chứng cứ và bản đồ.** Mỗi kết quả nhận mã E#; GeoJSON được lưu và gửi mã cho trình duyệt vẽ lớp mới.
- LLM viết câu trả lời.** Token được lọc qua guardrail đầu ra (che khóa bí mật, chặn lặp prompt) rồi stream tới người dùng, kèm E#.
- Kiểm chứng.** Mọi con số được đối chiếu với dữ liệu đã lấy; mã chứng cứ phải tồn tại; thiếu mã thì hệ thống tự bổ sung. Nếu bật AI kiểm chứng, một model khác đọc lại câu trả lời và nêu ý kiến.
- Lưu và học.** Tin nhắn, chứng cứ, kết quả kiểm chứng được lưu; lượt vừa xong được nhúng vector và tóm tắt chạy nền.

Luồng sự kiện gửi về trình duyệt

Sự kiện	Ý nghĩa
guardrail	Chặn, cảnh báo hoặc che nội dung
memory	Ký ức đã dùng (để kiểm tra)
tool_call	Công cụ và tham số LLM chọn
data	Dữ liệu bản đồ sẵn sàng
tool_result	Kết quả tóm tắt + mã chứng cứ
evidence	Chi tiết chứng cứ E#
token	Từng mảnh câu trả lời
verification	Kết quả đối chiếu số liệu
error / done	Lỗi có mã; kết thúc lượt

Bộ nhớ dài hạn: bốn lớp bù cho nhau

Trạng thái đối tượng	Tàu, công ty, thời gian đang bàn do code cập nhật từ kết quả công cụ → hiểu “nó”, “tàu đó”, “ngày hôm sau” dù lượt gốc đã trôi xa.
Tóm tắt cuốn chiếu	Các lượt rời cửa sổ được LLM tóm tắt, bắt buộc giữ nguyên mã hồ sơ, tên tàu và điều người dùng nhờ ghi nhớ. Chạy nền, không làm chậm lượt sau.
Ký ức vector	Mỗi lượt được nhúng vào pgvector; câu hỏi mới tìm lại các lượt cũ liên quan nhất (chỉ trong đúng hội thoại).
Cửa sổ nguyên văn	N lượt gần nhất giữ nguyên (cấu hình MEMORY_WINDOW_TURNS) để trả lời chính xác câu “trong số đó tàu nào xa nhất?”.

Kiểm chứng: với cửa sổ chỉ 2 lượt, sau 12 lượt hỏi xen giữa, chatbot vẫn trả lời đúng mã hồ sơ **HS-2026-117** và tàu **MSC MANYA** nêu ở lượt 1 — ký ức được tìm lại với độ tương đồng 0,585, cao hơn hẳn các lượt khác.

5 Dữ liệu, công cụ và chứng cứ

LLM truy cập dữ liệu chỉ qua 10 công cụ được kiểm soát


Công cụ	Trả lời câu hỏi	Nguồn dữ liệu	Bản đồ
search_vessels	Tìm tàu theo tên (chịu sai chính tả), MMSI, IMO, hồ hiệu	vessels	—
get_vessel_details	Hồ sơ tàu, công ty theo 6 vai trò, tóm tắt AIS	vessels, ownership, AIS, dark gap	—
find_company_vessels	Đội tàu của một công ty (gộp biển thể tên, không gộp pháp nhân khác)	ownership, vessels	—
get_position_at	Vị trí tại thời điểm: điểm trước/sau, độ lệch, nội suy	ais_positions, dark_gaps	điểm
get_last_position	Vị trí cuối cùng có trong dữ liệu	ais_positions	điểm
get_track	Hành trình, quãng đường, tốc độ TB, khe dữ liệu, cảnh báo	ais_positions	đường
get_dark_gaps	Các lần mất tín hiệu, tốc độ trước/sau	dark_gaps, ais_positions	điểm + đoạn
get_multi_tracks	Hành trình nhiều tàu theo công ty/loại tàu (LLM chỉ nhận tóm tắt)	ownership, vessels, AIS	nhiều đường
list_vessels	Đếm và liệt kê tàu: tổng số, theo loại/cờ, danh sách có phân trang, sắp theo trọng tải	vessels	—
search_knowledge	Kiến thức nghiệp vụ hàng hải, có trích dẫn	8 tài liệu, 31 đoạn	—

Xử lý dữ liệu nhiễu

- Tên tàu sai chính tả:** chuẩn hoá + so khớp trigram; nhiều kết quả thì hỏi lại người dùng.
- Tên công ty biển thể:** bỏ hậu tố pháp lý (CO, LTD, PTE, CORP...); pháp nhân khác tên vẫn tách riêng.
- Điểm GPS nhảy:** loại điểm có tốc độ suy ra tới cả điểm trước và sau vượt 50 knot.
- Tàu rời vùng:** khoảng trống trên 3 giờ không vẽ nối; quãng đường qua khe báo riêng, kèm cảnh báo.
- Nhãn loại tàu tiếng Anh:** 34 nhãn AIS gộp thành 10 nhóm (“tàu dầu” = tanker...).
- Thiếu dữ liệu:** vị trí lệch quá 60 phút thì nói rõ “không có dữ liệu gần thời điểm này”.

Chứng cứ gồm những gì

- Mã **E#** đánh số liên tục trong hội thoại.
- Công cụ đã dùng và tham số truy vấn.
- Bảng nguồn hoặc tài liệu nguồn.
- Giá trị gốc: điểm AIS, quãng đường, công ty theo vai trò...
- Nút phóng tới lớp bản đồ tương ứng.



Bấm vào mã chứng cứ trong câu trả lời để mở thẻ: bảng nguồn (Đăng kiểm tàu, Chủ sở hữu, Vị trí AIS, Mất tín hiệu), tham số và toàn bộ giá trị gốc.

Đối chiếu số liệu tự động: mọi con số có nghĩa trong câu trả lời phải khớp một giá trị trong dữ liệu đã truy vấn — cho phép làm tròn, tổng/hiệu/tỉ lệ và đổi đơn vị (hải lý↔km, giây↔giờ). Số không có nguồn hoặc mã chứng cứ không tồn tại sẽ hiện cảnh báo ngay dưới câu trả lời.

6 Công nghệ sử dụng

Chọn vì độ tin cậy, chi phí, khả năng giải thích và vận hành đơn giản

Hạng mục	Lựa chọn	Lý do
Mô hình ngôn ngữ	OpenAI gpt-4o-mini	Gọi công cụ song song ổn định, tiếng Việt tốt, rẻ (0,15/0,60 USD mỗi triệu token). Đổi model chỉ bằng biến môi trường; dùng được endpoint tương thích OpenAI (vLLM, Ollama).
Embedding	text-embedding-3-small	Rẻ, đa ngôn ngữ; tìm lại đúng lượt hội thoại chứa mã hồ sơ với độ tương đồng vượt trội.
Kiểm duyệt	OpenAI Moderation	Miễn phí, đa ngôn ngữ; có chính sách khi dịch vụ lỗi (cho qua hoặc chặn).
Backend	Python 3.12, FastAPI, asyncpg, sse-starlette	Bất đồng bộ, OpenAPI tự sinh, SSE có ping và xử lý ngắt kết nối; asyncpg nhanh, COPY nhị phân.
Điều phối LLM	Vòng lặp tự viết (~150 dòng)	Kiểm soát trọn vẹn sự kiện stream, chứng cứ, bộ nhớ, lỗi; dễ giải thích và test bằng LLM giả. LangChain/LangGraph thêm lớp trừu tượng khó ép theo định dạng đề yêu cầu.
Cơ sở dữ liệu	PostgreSQL 16 + PostGIS + pgvector + pg_trgm	Một hệ cho dữ liệu không gian, tìm kiếm mờ, vector và hội thoại; nhất quán giao dịch; ít thành phần vận hành.
RAG	Tìm kiếm lai vector (HNSW) + từ khoá, gộp RRF	Vector bất ý nghĩa, từ khoá bắt mã chính xác (511, IMO, ISM); văn bản bỏ dấu để gõ không dấu vẫn khớp.
Frontend	React 19, Vite, TypeScript, MapLibre GL	Bản đồ WebGL vẽ mượt hàng chục nghìn điểm, không cần khoá; bản đồ nền OpenFreeMap.
Độ bền AI	LLM dự phòng + AI kiểm chứng (tuỳ chọn)	Hết hạn key hay nhà cung cấp sập thì tự chuyển sang endpoint tương thích OpenAI khác (Groq, Together, DeepSeek, vLLM tự host); một model thứ hai có thể đọc lại câu trả lời để cho ý kiến độc lập; không có AI nào thì bản đồ, API dữ liệu và thống kê vẫn chạy.
Quan sát	Prometheus metrics, log JSON	Theo dõi độ trễ, token, chi phí, công cụ, guardrail, rate limit.
Kiểm thử	pytest, vitest, harness đánh giá	Test trên Postgres thật với bộ dữ liệu nhỏ; LLM giả cho test; harness chạy với model thật.
Triển khai	Docker Compose (db, api, web)	Một lệnh dựng toàn bộ; image không chạy root; nginx không quyền root phục vụ giao diện.

So sánh chiến lược bộ nhớ

Chiến lược	Ưu	Nhược
Cửa sổ trượt	Đơn giản, chính xác cho câu nói tiếp gần	Quên hẳn thông tin cũ
Tóm tắt	Giữ ý chính, kích thước ổn định	Mất chi tiết, tốn lượt gọi LLM
Truy xuất vector	Nhớ chi tiết cũ khi được hỏi đúng	Khó với câu hỏi dạng đại từ (“nó”)
Kết hợp (đã chọn)	Mỗi lớp bù điểm yếu lớp khác; có thêm trạng thái đối tượng	Phức tạp hơn; thêm một lần nhúng mỗi lượt (không đáng kể)

7 Bảo mật

Sáu lớp phòng thủ cho một câu hỏi

1. HTTP	Đăng nhập (token phiên ký HMAC, có hạn) hoặc API key, so sánh hằng thời gian; rate limit riêng cho đăng nhập, chat và API; giới hạn body 64 KB, mã yêu cầu, header bảo mật và Content-Security-Policy; lỗi 500 không lộ chi tiết.
2. Guardrail đầu vào	Chặn yêu cầu bỏ qua chỉ dẫn, đòi lộ system prompt/khoá, đổi vai, chèn thẻ hội thoại, jailbreak, mẫu SQL injection; kiểm duyệt nội dung. Chặn trước khi gọi LLM.
3. Prompt có phạm vi	Chỉ hỗ trợ hàng hải và dữ liệu này; coi nội dung trong kết quả công cụ và dữ liệu người dùng dán vào là dữ liệu, không phải chỉ dẫn.
4. Công cụ	Tham số kiểm bằng Pydantic, SQL viết sẵn có tham số, pool cơ sở dữ liệu chỉ đọc, timeout truy vấn, giới hạn số dòng.
5. Guardrail đầu ra	Lọc ngay trên luồng stream: che chuỗi giống khoá (sk-..., chuỗi kết nối DB), chặn lặp lại system prompt; sau đó đối chiếu số liệu và mã chứng cứ.
6. Quan sát	Metrics cho guardrail và rate limit, log JSON từng lượt, trang Thống kê; mọi quyết định guardrail lưu kèm tin nhắn để kiểm toán.

Mối đe dọa và biện pháp

Mối đe dọa	Biện pháp	Đã kiểm chứng
Prompt injection, jailbreak	Heuristic có trọng số (Việt/Anh, bỏ dấu); chặn không gọi LLM; nghi ngờ thì nhắc nhở hệ thống	red-team đạt
Dán “kết quả tool” giả	Phát hiện mẫu dữ liệu giả; buộc lần gọi đầu phải dùng công cụ thật	lỗi hổng tìm ra và đã vá
Lộ khoá, cấu hình, prompt	Lọc luồng token; không có đường đọc biến môi trường từ công cụ	test tự động
SQL injection, sửa/xoá dữ liệu	Không text-to-SQL; tham số hoá; pool chỉ đọc (DELETE bị từ chối)	test + red-team
Bị số liệu	Chứng cứ bắt buộc; đối chiếu số tự động; cảnh báo hiển thị	45/45 ca
Spam, đốt chi phí	Rate limit, giới hạn độ dài, số vòng công cụ tối đa, timeout, cache	test 429
XSS, clickjacking	React escape nội dung; Markdown không cho HTML; CSP chặt; X-Frame-Options	kiểm tra header
Người lạ dùng chatbot, dò mật khẩu	Form đăng nhập; mọi API cần token; giới hạn số lần thử theo IP; lỗi chung; mật khẩu băm PBKDF2 tùy chọn	test 401/429
Phụ thuộc nhà cung cấp AI	LLM dự phòng tự nhận việc; mất hết AI vẫn phục vụ dữ liệu, không trả lỗi 500	test tự động
Container bị chiếm quyền	API chạy user không root; nginx không quyền root; không có secret trong repo	uid 10001

Trước khi lên môi trường thật: bắt xác thực người dùng (OIDC) và phân quyền theo hội thoại; tạo role DB chỉ có quyền SELECT; chặn `/metrics`, `/docs` ở proxy; TLS/HSTS; chuyển rate limit sang Redis; quét phụ thuộc và image; đặt giới hạn chi tiêu OpenAI.

8 Tối ưu và hiệu năng

Nhanh, rẻ và nhẹ cho trình duyệt

2,1 s → 0,1 ms

vẽ 1.000 hành trình khi
trúng cache kết quả công
cụ

60 → 1

số truy vấn để lấy tốc độ
trước/sau cho 30 lần mất tín
hiệu (81 ms)

35.681 điểm

của 484 tàu gửi thẳng tới
bản đồ — LLM chỉ đọc bản
tóm tắt

~8 s

nạp toàn bộ 177 nghìn dòng
dữ liệu (COPY nhị phân)

Những tối ưu chính

- **Cache kết quả công cụ** (LRU + TTL): dữ liệu tàu là tĩnh nên cùng tham số cho cùng kết quả.
- **Truy vấn gộp**: `LATERAL JOIN` thay cho truy vấn lặp; chỉ mục (`vessel_id`, `event_ts`) cho “điểm gần nhất” lấy 1 dòng theo index.
- **Dữ liệu lớn không qua LLM**: bản đồ nhận GeoJSON trực tiếp; LLM chỉ đọc tóm tắt → ít token.
- **Giảm mẫu thông minh**: vượt 60 nghìn điểm thì giảm đều theo từng tàu, thống kê vẫn tính trên toàn bộ điểm.
- **Mạng**: nén gzip (trừ stream), dữ liệu bản đồ có ETag và cache bất biến, asset frontend cache vĩnh viễn.
- **Bộ nhớ**: kết quả công cụ cũ trong cửa sổ được rút gọn; nhúng và tóm tắt chạy nền.
- **Prompt caching**: system prompt và mô tả công cụ cố định ở đầu để OpenAI cache phần tiền tố.
- **WebGL**: nhiều hành trình vẽ trong một lớp duy nhất, màu theo thứ hạng quãng đường.

Độ trễ và chi phí đo thực tế

Chỉ số (45 ca, gpt-4o-mini)	Giá trị
Token đầu tiên, trung vị / p95	4,9 s / 5,8 s
Toàn lượt, trung vị / p95	5,4 s / 8,4 s
Truy vấn công cụ	1–80 ms (1.000 tàu × 3 ngày ≈ 2 s)
Token vào / ra mỗi lượt	~9 nghìn / ~140
Chi phí mỗi câu hỏi	≈ 0,0015 USD
Toàn bộ 45 ca đánh giá	≈ 0,065 USD

Độ trễ gồm kiểm duyệt nội dung, 1–2 lần gọi LLM khi có công cụ và đoạn đệm ngắn của guardrail đầu ra (để kịp che thông tin nhạy cảm trước khi hiển thị).

Chất lượng dữ liệu tính toán

Quãng đường do hệ thống tính (haversine, đã loại điểm nhiễu) được đối chiếu độc lập với PostGIS đo trắc địa trên dữ liệu gốc: chênh lệch dưới **0,5%** (ví dụ 449,39 so với 447,94 hải lý).

9 Chất lượng và kiểm thử

Kiểm thử tự động ở ba tầng

✓ 189 test backend

Tầng truy vấn trên PostgreSQL thật (bộ dữ liệu nhỏ có cài sẵn nhiều), công cụ, bộ nhớ, guardrail, RAG, chứng cứ, bảo mật, đăng nhập, thống kê, tích hợp API/stream. LLM giả nên không tốn phí.

✓ 17 test frontend

Bộ đọc stream (sự kiện bị cắt giữa nhiều gói), dừng lại hội thoại cũ, nhấn tham số, liên kết mã chứng cứ, định dạng thống kê, phiên đăng nhập.

📊 Harness đánh giá

Chạy với model thật qua API: câu hỏi sinh từ dữ liệu (đáp án bằng SQL), ca kiến thức, hội thoại nhiều lượt, red-team, ngoài phạm vi, thiếu dữ liệu.

Kết quả harness: 45/45 ca đạt

Số ca theo nhóm (mọi ca đều đạt). Tiêu chí chấm: gọi đúng công cụ, đúng số liệu, số liệu có nguồn, có mã chứng cứ, từ chối đúng lúc, không lỗi.

Tra cứu dữ liệu tàu		29 / 29 đạt
Kiến thức (RAG)		5 / 5 đạt
Red-team		5 / 5 đạt
Hội thoại nhiều lượt		2 / 2 đạt
Ngoài phạm vi		2 / 2 đạt
Thiếu dữ liệu		2 / 2 đạt

Tra cứu dữ liệu gồm cả 3 ca đếm/liệt kê tàu. Chạy thêm với bộ câu hỏi sinh bằng seed khác: 26/26 đạt — hệ thống không phụ thuộc vào kịch bản mẫu.

Harness đã tìm ra và giúp sửa

Vấn đề phát hiện	Cách sửa
Model tin “kết quả tool” do người dùng dán vào và bịa mã chứng cứ	Guardrail nhận diện dữ liệu dán giả, buộc gọi công cụ thật (<code>tool_choice=required</code>) + quy tắc prompt
Quy tắc phạm vi quá chặt: từ chối cả câu hỏi về nội dung đã nhờ ghi nhớ	Viết lại phạm vi: vẫn trả lời về cuộc trò chuyện và nói “dữ liệu không có” thay vì từ chối
Model đôi khi quên trích mã chứng cứ	Hệ thống tự bổ sung dòng chứng cứ → 100% câu trả lời dùng dữ liệu có chứng cứ
Kịch bản 5: giữ nhằm bộ lọc công ty khi hỏi “toàn bộ tàu cargo”	Quy tắc đổi phạm vi câu nói tiếp + mô tả tham số công cụ
OpenAI giới hạn tần suất khi chạy song song	Thử lại có backoff cấu hình được; thông báo lỗi thân thiện

Transcript kịch bản đề bài (5 kịch bản + 4 biến thể đổi tàu, thời điểm, cách hỏi) nằm trong thư mục `results/` , kèm đáp án tính bằng SQL để đối chiếu. Kịch bản bộ nhớ dài chạy với cửa sổ chỉ 2 lượt.

10 Hướng mở rộng

Từ bản demo 3 ngày dữ liệu tới nền tảng giám sát hàng hải

Giai đoạn 1 — sản phẩm

Người dùng và tính năng

- Đăng nhập (OIDC), phân quyền hội thoại, không gian làm việc theo nhóm.
- Cảnh báo chủ động: tàu tắt AIS, đi vào vùng quan tâm, đổi cờ/chủ.
- Xuất báo cáo PDF/Excel kèm chứng cứ; chia sẻ hội thoại.
- Địa danh và cảng (reverse geocoding) từ nguồn tin cậy.
- Đa ngôn ngữ; hỏi bằng giọng nói.

Giai đoạn 2 — dữ liệu lớn

Vài chục triệu điểm/ngày

- Phân vùng bảng vị trí theo ngày (TimescaleDB), nén dữ liệu cũ, chỉ mục BRIN.
- Tổng hợp sẵn theo giờ/tàu cho quãng đường, xếp hạng.
- Nạp dữ liệu dạng luồng (Kafka) thay CSV; dark gap tính tăng dần (Flink).
- Phân tích toàn đội tàu trên kho cột (ClickHouse, Parquet).
- Bản đồ bằng vector tile động (ST_AsMVT, Martin), deck.gl cho hàng triệu điểm.

Giai đoạn 3 — nền tảng

Vận hành và AI

- Nhiều bản API sau load balancer; khoá, cache, rate limit trên Redis; hàng đợi tác vụ nền.
- Read replica cho truy vấn công cụ; vector DB riêng khi ký ức lớn.
- Bộ phân loại injection học máy; mô hình thứ hai kiểm tra câu trả lời rủi ro cao.
- Harness chạy trong CI khi đổi prompt/model; LLM làm giám khảo cho câu trả lời mô tả.
- Định tuyến model theo độ khó để tối ưu chi phí.

Mở rộng nguồn dữ liệu và bài toán



Nguồn dữ liệu mới

- Ảnh vệ tinh / radar SAR để phát hiện “tàu tối” không phát AIS.
- Danh sách trừng phạt, lịch sử kiểm tra cảng (PSC), sự cố hàng hải.
- Thời tiết, dòng chảy, vùng đánh bắt, vùng cấm.
- Lịch cập cảng, dữ liệu thương mại, hàng hoá.




Phân tích nâng cao

- Phát hiện hành vi bất thường: gặp nhau trên biển (STS), đổi hướng đột ngột, giả mạo vị trí.
- Dự đoán thời gian đến cảng (ETA) và tuyến đi.
- Chấm điểm rủi ro tàu/công ty có giải thích và chứng cứ.
- Đồ thị quan hệ sở hữu nhiều tầng.


Vì sao mở rộng được: kiến trúc đã tách giao diện LLM/embedding khỏi logic (đổi nhà cung cấp dễ dàng), công cụ đăng ký theo cùng một khuôn (thêm công cụ mới không đụng vòng lặp chat), sự kiện stream có kiểu (giao diện mới chỉ cần lắng nghe), và mọi thiết lập nằm trong biến môi trường.

11 Giao diện

Lấy cảm hứng từ hải đồ: bản đồ là trung tâm, hỏi đáp bên phải



Hành trình của 484 tàu hàng trong ngày 11/09/2026 (35,7 nghìn điểm) với bảng xếp hạng quãng đường cùng màu tuyến; câu trả lời có bảng số liệu và bước tra cứu.



Câu hỏi nối tiếp “hiện thêm các lần tắt AIS của nó” thêm lớp mắt tin hiệu lên hành trình.

Mã chứng cứ E3, E4 trong câu trả lời và nhãn “Đã đối chiếu 16 số liệu với dữ liệu truy vấn”.

Rõ ràng

Câu hỏi và câu trả lời tách bạch; mỗi bước tra cứu hiện biểu tượng, trạng thái và tham số bằng tiếng Việt.

Kiểm chứng được

Chip chứng cứ bám được; thẻ chứng cứ có bảng nguồn và giá trị gốc; nút phóng to/lời bản đồ.

Dành cho người đánh giá


Màn hình đăng nhập có sẵn link tới bản trình bày 6 slide và tài liệu này; sau khi đăng nhập có kịch bản demo 11 câu bấm là hỏi, cùng các nút mở thống kê, kiểm tra sức khỏe, tài liệu API và mã nguồn.

Mọi thiết bị

Máy tính: ba cột. Điện thoại: tab Hỏi đáp / Bản đồ, ngăn kéo danh sách hỏi thoại. Hỗ trợ bàn phím và giảm chuyển động.

12 Thống kê vận hành

Theo dõi chi phí, độ trễ, chất lượng và an toàn ngay trong giao diện



13 Phụ lục: cài đặt và API

Chạy toàn bộ hệ thống trong vài lệnh

Cài đặt bằng Docker

```
cp .env.example .env
# điền OPENAI_API_KEY, đặt CSV vào ./data
docker compose up -d --build
docker compose run --rm api \
  python scripts/load_data.py

# giao diện: http://localhost:5173
# đăng nhập: demo / demo (AUTH_USERS)
# API docs: http://localhost:8000/docs
```

Kiểm thử và đánh giá

```
.venv/bin/pytest -q
cd frontend && npm test
python evals/generate.py --seed 7
python evals/run.py --min-pass-rate 0.85
```

Cấu hình chính

Biến	Ý nghĩa
LLM_MODEL	Tên model chat
MEMORY_WINDOW_TURNS	Số lượt giữ nguyên văn
AUTH_USERS	Tài khoản đăng nhập
SESSION_SECRET	Khoá ký token phiên
RATE_LIMIT_CHAT_PER_MINUTE	Giới hạn câu hỏi/phút
GUARDRAIL_*	Ngưỡng injection, moderation, đối chiếu số
FALLBACK_LLM_*	AI dự phòng khi nhà cung cấp chính lỗi
VERIFIER_LLM_*	AI kiểm chứng câu trả lời (tùy chọn)
RAG_*	Kho tri thức: độ dài đoạn, top-k

Toàn bộ 60+ biến được giải thích trong `.env.example`.

API chính

Method	Đường dẫn	Mô tả
POST	/conversations	Tạo hội thoại
GET	/conversations	Danh sách
GET	/conversations/{id}/messages	Tin nhắn, chứng cứ
DELETE	/conversations/{id}	Xoá (kèm ký ức)
POST	/conversations/{id}/chat	Hỏi, nhận luồng SSE
GET	/map-data/{id}	GeoJSON một lớp
GET	/tracks	Nhiều hành trình, phân trang
POST	/auth/login	Đăng nhập, nhận token
GET	/stats	Số liệu vận hành
GET	/health, /metrics	Sức khoẻ, Prometheus

Xem stream trong terminal

```
curl -N -X POST
localhost:8000/conversations/$CID/chat \
  -H "Authorization: Bearer $TOKEN" \
  -H 'Content-Type: application/json' \
  -d '{"message": "Tàu KOTA GAYA ở đâu lúc 21:00 11/09?"}'

event: tool_call
event: evidence {"id": "E1", ...}
event: token {"text": "Lúc 21:00..." }
event: verification {"grounded": true}
event: done
```

Tài liệu trong repository

- `README.md` — cài đặt, trạng thái yêu cầu
- `docs/architecture.md` — kiến trúc chi tiết
- `docs/research.md` — nghiên cứu, lựa chọn
- `docs/api.md`, `docs/openapi.json`
- `SECURITY.md` — mô hình đe dọa
- `results/` — transcript, đáp án SQL, báo cáo đánh giá

Repository: github.com/theluu/Rag-VegaStar — lịch sử commit đi từng bước, từ dữ liệu tới tài liệu.